1 · บทบาท EDA & Anscombe's Quartet

Lect05 p04,08 · W4 Q2–3

- W4-Q2 **บทบาท EDA ใน CRISP-DS:** เป็น **Iterative Checkpoint** ย้อนกลับไปทบทวนคำถาม/Data Prep ได้เมื่อพบปัญหา · **Informs modeling** แต่ **ไม่ได้เลือกโมเดลให้อัตโนมัติ**
- W4-Q3 **ห้ามเริ่มด้วยการสร้างทุกกราฟ:** ต้องเริ่มจาก **Analytical Question** กำหนดตัวแปรและการเปรียบเทียบที่ตรงเป้าหมาย (Start with Question, Not Dataset)
- **Anscombe's Quartet (p08):** ข้อมูล 4 ชุดค่าสถิติเท่ากันเป๊ะ ($\bar{x}=9$, $\mathrm{Var}(X)=11$, $\bar{y}=7.5$, $\mathrm{Var}(Y)=4.125$, $r=0.816$, $y=3+0.5x$) แต่พล็อตกราฟแล้วต่างกันสิ้นเชิง (เชิงเส้น, พาราโบลา, 1 Outlier ดึง, จุดเกาะกลุ่มมี 1 Leverage Point) → **ห้ามเชื่อแค่ตัวเลขสถิติ ต้องพล็อตกราฟเสมอ!**

2 · สถิติค่ากลาง & การกระจายตามรูปร่างข้อมูล

Lect05 p06–07 · W4 Q4–5

ลักษณะข้อมูล	คู่สถิติที่ต้องเลือกใช้	เหตุผลทางสถิติและจุดหลอก
Symmetric (สมมาตร)	**Mean + SD** (หรือ Variance)	Mean ≈ Median ≈ Mode ไม่มีค่าสุดขั้วดึง
Skewed / มี Outlier	**Median + IQR** W4-Q4	**Robust (ทนทาน):** Mean และ SD ไวต่อค่าสุดขั้วมาก
Categorical (กลุ่ม)	**Mode** (ความถี่สูงสุด)	ห้ามใช้ Mean/Median กับข้อมูลนามบัญญัติ

- **ทิศทางเบ้: เบ้ขวา (+):** หางยาวขวา Mode < Median < Mean · **เบ้ซ้าย (−):** Mean < Median < Mode
- W4-Q5 **กราฟ 2 ยอด (Bimodal):** ตีความว่า **มีกลุ่มย่อย (Sub-groups) มากกว่า 1 กลุ่มแฝงอยู่** (ห้ามตัดทิ้ง หรือตอบว่า SD = 0)

3 · Boxplot Outlier & กฎ Tukey's Fences

Lect05 p07,17 · W4 Q6–7

$\mathrm{Range} = \mathrm{Max} - \mathrm{Min} \cdot \mathrm{IQR} = Q3 - Q1 \cdot \mathrm{Var}(\sigma^2) = \Sigma(x_i-\mu)^2/N \cdot \mathrm{SD}(\sigma) = \sqrt{\mathrm{Var}}$

สูตรรั้ว Boxplot: $\mathrm{Lower} = Q1 - 1.5\times\mathrm{IQR}$ | $\mathrm{Upper} = Q3 + 1.5\times\mathrm{IQR}$ W4-Q6

- **ตัวอย่างคำนวณ:** $Q1=30$, $Q3=70$ → $\mathrm{IQR}=40$ → $\mathrm{Upper} = 70+1.5(40) = 130$ (ถ้าพบ $x=140 > 130$ ถือว่าอยู่นอกรั้ว)
- **กฎเส้นหนวด (Whisker):** ลากไปหยุดที่ **ค่าจริงในชุดข้อมูลที่ไม่เกินรั้ว** (ไม่ได้ลากไปหยุดที่ค่า Fence!)
- W4-Q7 **พบค่านอกรั้วทำอย่างไร:** ถือเป็นเพียง **Potential Outlier เพื่อสืบค้นบริบทก่อน** (อาจเป็น Error หรือเป็น Real Event เช่น ยอดซื้อ VIP) **ห้ามลบทิ้งหรือแทนที่อัตโนมัติ!**

ตัวลวง W4-Q6: ช้อยส์หลอกใช้ $Q3 + 3.0\times\mathrm{IQR}$ (extreme outlier) หรือใช้ $\mathrm{Median} + 1.5\times\mathrm{IQR}$ (ผิดตัวตั้งต้น)

4 · การเลือกชาร์ต · สี · Accessibility · ความเป็นธรรม

Lect05 p14–25 · W4 Q8,10,11

วัตถุประสงค์	กราฟที่ถูกต้อง	กฎเหล็กการออกแบบและเปรียบเทียบ
Distribution / Outlier	Histogram, **Boxplot**	Boxplot เห็น Median, IQR, Skewness, Outlier ชัดสุด
Comparison	Bar / Column Chart	**แกนตัวเลขต้องเริ่มที่ 0 เสมอ** ห้ามตัดแกน (Truncate)
Relationship	Scatter Plot	ดูทิศทาง/กลุ่ม · Pie Chart ใช้เมื่อหมวดหมู่ **≤ 5 ส่วน**
Trend over Time	Line Chart	แกน X เวลาต้องเรียงตามลำดับต่อเนื่อง ห้ามสลับหมวด

- W4-Q8 **Color Palettes 3 แบบ:** ① **Sequential:** เรียงต่ำ→สูง · ② **Diverging:** มี **ค่ากลางอ้างอิง (Meaningful Midpoint)** เช่น อุณหภูมิเทียบเป้าหมาย · ③ **Qualitative:** หมวดหมู่ไม่มีลำดับ
- W4-Q10 **Accessibility (ตาบอดสี):** ใช้ **Redundant Encoding** (สี + รูปร่าง/เส้น/ป้ายกำกับ) · **ห้ามใช้คู่สีแดง-เขียวเด็ดขาด!**
- W4-Q11 **Responsible Comparison:** ตรวจว่า **กลุ่มย่อยเล็กเกินจนเสี่ยงระบุตัวตน (Privacy Risk)** หรือไม่ และตรวจ Differential Missingness (ห้ามตัดทิ้งดื้อๆ)

5 · Correlation vs Causation

Lect05 p09 · W4 Q9

- W4-Q9 **ความต่างสำคัญ:** Correlation ($r \in [-1, +1]$) บอกการแปรผันร่วม **แต่ไม่ได้พิสูจน์ว่าเป็นเหตุเป็นผล (Causation)** แม้ $r \approx \pm 1$ ก็สรุปเหตุผลทันทีไม่ได้
- **4 ทางเลือกที่ต้องตรวจก่อนสรุปเหตุผล:** ① **Confounding** (ตัวแปรที่ 3 ซ่อนอยู่) · ② **Reverse Direction** ($Y \to X$) · ③ **Selection Effects** (อคติการสุ่ม) · ④ **Coincidence** (บังเอิญพ้องกัน)

6 · Feature Scaling & วิธีคำนวณโจทย์จริง

Lect04.2 p20–22 · W7 Q4

วิธี Scale	สูตรคำนวณ	คุณสมบัติและการตีความ
Min-Max	$x' = [(x-x_{min}) \div (x_{max}-x_{min})] \cdot (U-L)+L$	บีบค่าลงช่วง [0,1] หรือ [L,U] · ไวต่อ Outlier
Z-Score	$z = (x-\mu) \div \sigma$	ได้ $\mu = 0$, $\sigma = 1$ · บอกว่าห่างจาก μ กี่เท่าของ SD

- **ตัวอย่างคำนวณสไลด์:** รายได้ $\mathrm{Min}=55k$, $\mathrm{Max}=150k$ ลูกค้าได้ $x=75k$
  - **Min-Max [0, 1]:** $(75k-55k) \div (150k-55k) = 20k \div 95k = 0.211$
  - **Z-Score** ($\mu=90{,}833$, $\sigma=35{,}286$): $z = (75{,}000-90{,}833) \div 35{,}286 = -0.45$ (ต่ำกว่าเฉลี่ย 0.45 SD)
- W7-Q4 **กฎเหล็ก: ต้อง Scale** ก่อนใช้ **K-Means, 5-NN, SVM, PCA** เพื่อ **ป้องกันไม่ให้ตัวแปรหน่วยใหญ่ (เช่น Spending) ครอบงำระยะห่างทั้งหมด** · ส่วน **Decision Tree / Random Forest ไม่ต้อง Scale**

7 · Modeling Framework & การแยกองค์ประกอบโจทย์

Lect06 · W5 Q1–8

- W5-Q1 **บทบาท Modeling:** ส่งสัญญาณย้อนกลับไปปรับปรุง Data Prep หรือ EDA ได้ (ไม่ใช่ One-way)
- W5-Q2 **โจทย์ที่ไม่ต้องใช้ ML (ใช้แค่ Descriptive):** คำถามที่ถาม **สถิติสรุปอดีต** เช่น **"เดือนที่แล้วมูลค่าคำสั่งซื้อมัธยฐานเท่าใด"** · ถ้าทายยอด 60 วัน / ใครจะเลิกใช้ = ต้องใช้ ML
- W5-Q3 **ลำดับ 5 ขั้น:** Problem → Setting → Task → Algorithm (สูตรต้นไม้) → **Trained Model (Fitted Decision Tree ที่ผ่านการ Train แล้ว)**

องค์ประกอบ W5-Q4	วิธีแยกแยะจากโจทย์ "ทำนายลูกค้าหยุดซื้อใน 60 วัน"
Observation Unit	ลูกค้าแต่ละราย ณ วัน Observation Date (หน่วยที่ถูกสังเกต)
Feature (X)	**ความถี่สั่งซื้อในอดีต และระยะเวลาจากการซื้อล่าสุด (Recency/Frequency)**
Target / Label (Y)	สถานะหยุดซื้อหรือไม่หยุดซื้อภายใน 60 วันข้างหน้า (คำตอบที่ใช้สอนโมเดล)
Output (Ŷ)	ความน่าจะเป็น หรือคลาสที่ตัวแบบคำนวณออกมาเป็นผลลัพธ์

- W5-Q5,6,7 **เลือก Task:** มี Target = **Supervised** [ทายตัวเลขต่อเนื่อง (กี่บาท) = **Regression** | ทายหมวดหมู่ = **Classification**] · ไม่มี Target = **Unsupervised** [จัดกลุ่มตามความคล้าย = **Clustering**]
- W5-Q8 **Simple Baseline:** เริ่มต้นเพื่อสร้าง **จุดอ้างอิงวัดว่าโมเดลซับซ้อนให้ผลคุ้มค่าหรือไม่**

8 · 3-Way Split & การวินิจฉัย Overfitting

Lect06–07 · W5 Q9–10 · W6

ชุดข้อมูล W5-Q9	สัดส่วน	หน้าที่หลัก (ห้ามสลับ Validation กับ Test เด็ดขาด!)
Training Data	60–70%	ใช้ **เรียนรู้พารามิเตอร์** (Fit model / สร้างกิ่งการตัดสินใจ)
Validation Data	15–20%	ใช้ **ตัดสินใจระหว่างพัฒนา**, จูน Hyperparameter (max_depth W6-Q6), เลือกโมเดล
Test Data	15–20%	ใช้ **ตรวจสอบขั้นสุดท้ายด้วยหลักฐานอิสระครั้งเดียวจบ** **(ห้ามนำมาจูนซ้ำ! W6-Q2)**

W5-Q10 W6-Q7 **วิธีดูอาการโมเดล: Train สูง (~100%) แต่ Val/Test ต่ำมาก = Overfitting (High Variance)** (เกิดเมื่อใช้ **Unrestricted Tree** W6-Q5) · **ต่ำทั้งคู่ = Underfitting (High Bias)** · **สูงใกล้เคียงกัน = Appropriate Fit**

9 · 4 Candidate Models & โครงสร้างต้นไม้

Lect07 p09,33 · W6 Q3–4

- W6-Q4 **โครงสร้างต้นไม้: Root Node** (บนสุด) → **Internal Node** (จุดแยกเงื่อนไข) → **Branch** (กิ่ง) → **Leaf Node (จุดสิ้นสุดที่ให้ผลลัพธ์เป็น Predicted Class)**
- W6-Q3 **กลไกแตกกิ่ง:** ทำงานแบบ **Greedy Algorithm** เลือกคู่ Feature + Threshold ที่ได้ **Weighted Gini ต่ำสุด** ณ Node ปัจจุบัน **โดยไม่รับประกัน Global Optimum ทั้งต้น!**

Candidate Model	จุดแข็งสำคัญ	ข้อจำกัด / ข้อควรระวัง
Decision Tree	อธิบายกฎง่าย (White-box), **ไม่ต้อง Scale**	Overfit ง่ายถ้าไม่คุม max_depth / Prune
5-NN (k-NN)	เทียบเพื่อนบ้านใกล้สุด 5 จุด ไม่ต้องเทรนสมการ	**ไวต่อ Scale มาก**, ทายช้าเมื่อข้อมูลใหญ่
Naive Bayes	คำนวณความน่าจะเป็นเร็วมาก	สมมติว่าทุก Feature เป็นอิสระต่อกัน
Neural Network	จับความสัมพันธ์ซับซ้อน Non-linear ได้ดี	**Black-box ชัดสุด (Hidden Layers นับร้อย)** มนุษย์แกะเหตุผลยาก

10 · วิธีคำนวณ Gini Impurity & การเลือก Split

Lect07 p11–12

$\mathrm{Gini}(t) = 1 - \Sigma\, p_i^2$ (Pure = 0, 50:50 แย่สุด = 0.500) · $\mathrm{Gini}_{split} = (n_L/N)\mathrm{Gini}(L) + (n_R/N)\mathrm{Gini}(R)$

วิธีทำโจทย์เทียบ Split (N=12: 6 Active, 6 Inactive → Gini(Parent) = 0.500):

1. **หา Gini กิ่งย่อย:** กิ่ง [5,1] → $1-(5/6)^2-(1/6)^2 = 10/36 = 0.278$ · กิ่ง [2,4] → $1-(2/6)^2-(4/6)^2 = 16/36 = 0.444$
2. **เทียบถ่วงน้ำหนัก (Gini_{split}) & Gain ($\mathrm{Gini}(\mathrm{Parent}) - \mathrm{Gini}_{split}$):**
   - **Split A** (days ≤ 45 แบ่ง [5,1] | [1,5]): $\mathrm{Gini}_{split} = 0.278$ → $\mathrm{Gain} = 0.500 - 0.278 = 0.222$ **(ชนะ!)**
   - **Split B** (purchases ≤ 2 แบ่ง [2,4] | [4,2]): $\mathrm{Gini}_{split} = 0.444$ → $\mathrm{Gain} = 0.500 - 0.444 = 0.056$
3. **กฎตัดสิน:** เลือก Split ที่ **Gini_{split} ต่ำสุด (= Gain สูงสุดเสมอ)**

- **การทำนายที่ Leaf Node (p17):** โหนดมี [4 Inactive, 1 Active] → ทาย Inactive ด้วยค่าความน่าจะเป็น $P = 4/5 = 0.80$

11 · Tree Depth · Bias–Variance · Ensemble

Lect07 p19,31 · W6 Q5-

ความลึกต้นไม้	Bias	Variance	พฤติกรรมโมเดลในสไลด์และข้อสอบ
Depth = 1 (ตื้น)	สูง	ต่ำ	**Underfitting** (กฎง่ายเกินไป จับรูปแบบไม่พอ)
Depth = 3 (พอดี)	ต่ำพอดี	ต่ำพอดี	**Appropriate Fit — ถูกเลือกใช้ในสไลด์ (Val ดีสุด)** W6-Q6
Unrestricted (ไม่จำกัด)	~0	สูงสุด	**Train Acc 100% แต่เสี่ยง Overfitting สูงมาก!** W6-Q5

วิธีแก้ Overfit: Pre-pruning (คุม max_depth) · Post-pruning · **Bagging/Random Forest** (ลด Variance) · **Boosting** (ลด Bias)

12 · Confusion Matrix & เลือก Metric ธุรกิจ

Lect07 p22–35 · W6 Q8–11

โครงสร้างสไลด์อาจารย์: แถว (Row) = Actual (จริง) · คอลัมน์ (Col) = Predicted (ทำนาย)

Metric	สูตรคำนวณ	เกณฑ์การเลือกใช้ตามสถานการณ์ธุรกิจ
Accuracy	$(TP+TN) \div N_{total}$	ใช้เมื่อคลาสสมดุล · W6-Q8 **ห้ามใช้เดี่ยวๆ เมื่อ Imbalance!** (ทายทุกคน Active 95% ก็ได้ Acc 95% ทั้งที่ไม่เจอกลุ่มเสี่ยง)
Precision	$TP \div (TP + FP)$	W6-Q9 **เน้นลด FP:** ใช้เมื่อ **ทีมงานติดต่อจำกัด / ต้นทุนยิ่งข้อเสนอแพง** / Spam filter (ไม่อยากทายบวกมั่วจนเสียเงินฟรี)
Recall	$TP \div (TP + FN)$	**เน้นลด FN:** ใช้เมื่อ **การหลุดกลุ่มเสี่ยงเสียหายหนักมาก** (คัดกรองโรคร้าย, ทุจริต Fraud, ลูกค้า VIP เสี่ยงเลิกใช้)
F1-Score	$2 \cdot P \cdot R \div (P + R)$	ค่าเฉลี่ยฮาร์โมนิก ใช้เมื่อต้องการ **สมดุลทั้ง Precision และ Recall**

W6-Q10 **วิธีตีความ FP vs FN (ยึด Positive Class ที่โจทย์กำหนดเป็นหลัก!):**

- **ตัวอย่างนักกีฬา (Positive = พร้อมลงเล่น play):**
  - **False Negative (FN = ทายว่าไม่พร้อม แต่จริงพร้อม): ทำให้ทีมพลาดโอกาสส่งนักกีฬาที่ฟิตพร้อมลงสนาม!**
  - **False Positive (FP = ทายว่าพร้อม แต่จริงเจ็บ):** ส่งนักกีฬาที่ยังไม่พร้อมลงสนาม เสี่ยงบาดเจ็บซ้ำ!
- **Threshold:** ลด (<0.5) ทายบวกง่ายขึ้น → **Recall ↑, Precision ↓** · เพิ่ม (>0.5) → **Precision ↑, Recall ↓**

13 · ตัวเลข 3 เคสจริงในสไลด์ (FIFA · HW#1 · HW#2)

Lect07 p23–35

กรณีศึกษาในสไลด์	TP	FN	FP	TN	Acc	Prec	Rec	F1
1. FIFA (Pos=play, N=10)	4	2	1	3	.70	.80	.67	.73
2. HW#1 (Pos=Inactive, N=10)	3	2	2	3	.60	.60	.60	.60
3. HW#2 Model A (N=100)	24	16	3	57	.81	**.89**	.60	.72
3. HW#2 Model B	36	4	18	42	.78	.67	**.90**	.77
3. HW#2 Model C (ชนะ)	32	8	7	53	**.85**	.82	.80	**.81**

HW#1 ไล่นับ 10 แถว: O1(Y/Y) O2(N/N) O3(Y/N) O4(N/Y) O5(Y/Y) O6(N/N) O7(N/Y) O8(Y/Y) O9(N/N) O10(Y/N) → TP=3, TN=3, FP=2, FN=2 ได้ 0.60 เท่ากันหมด · **HW#2:** งบจำกัดเลือก **A** (Prec .89) · กลัวพลาดคนเสี่ยงเลือก **B** (Rec .90) · สมดุลเลือก **C** (Acc .85, F1 .81 ชนะ)

14 · K-Means Centroid ละเอียดทุกสเต็ป ครบ 3 รอบจน Converge + เฉลยการบ้าน

Lect08 p10–44 · W7 Q2–8

- W7-Q3 **เป้าหมาย Good Clustering: Maximize Intra-cluster** (สมาชิกในกลุ่มแน่นสุด) + **Minimize Inter-cluster** (ระยะห่างข้ามกลุ่มมากสุด)
- W7-Q4 **กฎเหล็ก Scaling:** ต้องทำ Standardize/Scale ก่อน K-Means เสมอ ป้องกันตัวแปรค่าใหญ่กลืนระยะทาง · W7-Q8 **ไวต่อ Outliers, ติด Local Optimum** แต่เร็วมาก **O(tkn)**
- **คุณสมบัติ Metric ระยะทาง D(A,B):** ① Symmetry: D(A,B)=D(B,A) · ② Self-similarity: D=0 ⇔ A=B · ③ Positivity: D ≥ 0 · ④ Triangle Inequality: D(A,C) ≤ D(A,B)+D(B,C)
- **กฎ Tie-Breaking (สไลด์หน้า 44):** ถ้าระยะทางเท่ากันพอดี **ให้เลือกเข้า Cluster หมายเลขต่ำกว่าเสมอ** (เช่น d(C₁)=d(C₂)=2 ให้เลือก C₁)

พิกัด 8 จุดตั้งต้น (สไลด์ p25):
$A_1(2,10)$, $A_2(2,5)$, $A_3(8,4)$, $A_4(5,8)$
$A_5(7,5)$, $A_6(6,4)$, $A_7(1,2)$, $A_8(4,9)$

W7-Q5 รอบที่ 1: เริ่ม $C_1(2,10)$, $C_2(5,8)$, $C_3(1,2)$

- คิด Manhattan เช่น A_2 เทียบ C_3: $|2-1|+|5-2| = 1+3 = 4$
- สรุปกลุ่มรอบ 1: $C_1=\{A_1\}$, $C_2=\{A_3,A_4,A_5,A_6,A_8\}$, $C_3=\{A_2,A_7\}$

W7-Q7 Centroid ใหม่รอบ 1 (แจกแจงสูตร):

- $C_1 = (2, 10)$ (มีจุดเดียว)
- $C_2 = ((8+5+7+6+4)/5, (4+8+5+4+9)/5) = (30/5, 30/5) = (6.0, 6.0)$
- $C_3 = ((2+1)/2, (5+2)/2) = (3/2, 7/2) = (1.5, 3.5)$

รอบที่ 2 (เทียบ $C_1(2,10)$, $C_2(6,6)$, $C_3(1.5,3.5)$):

- ตรวจสอบจุด $A_8(4,9)$:
  $d(A_8, C_1) = |4-2| + |9-10| = 2 + 1 = 3$
  $d(A_8, C_2) = |4-6| + |9-6| = 2 + 3 = 5$
  → ระยะห่างเข้า C_1 น้อยกว่า! **A_8 จึงย้ายจากกลุ่ม 2 ไปกลุ่ม 1!**
  ผลกลุ่ม: $C_1=\{A_1,A_8\}$, $C_2=\{A_3,A_4,A_5,A_6\}$, $C_3=\{A_2,A_7\}$
- **Centroid ใหม่รอบ 2:**
  $C_1 = ((2+4)/2, (10+9)/2) = (6/2, 19/2) = (3.0, 9.5)$
  $C_2 = ((8+5+7+6)/4, (4+8+5+4)/4) = (26/4, 21/4) = (6.5, 5.25)$
  $C_3 = (1.5, 3.5)$

รอบที 3 (เทียบ $C_1(3,9.5)$, $C_2(6.5,5.25)$, $C_3(1.5,3.5)$):

- จุด $A_4(5,8)$: $d(C_1)=|5-3|+|8-9.5|=3.5 < d(C_2)=4.25$ → **A_4 ย้ายจากกลุ่ม 2 เข้ากลุ่ม 1!**
- **Centroid ใหม่รอบ 3:** $C_1=\{A_1,A_8,A_4\}$=**(3.67, 9.0)**, $C_2=\{A_3,A_5,A_6\}$=**(7.0, 4.33)**, $C_3=\{A_2,A_7\}$=**(1.5, 3.5)**
- รอบ 4: ไม่มีจุดใดย้ายกลุ่มอีก → **Converges หยุดทำงาน!**

เฉลยการบ้านสไลด์หน้า 44 (ออกสอบบ่อย):

- **ข้อ 1 (K=2, Manhattan, $C_1=A_3(8,4)$, $C_2=A_6(6,4)$):**
  จุด $A_5(7,5)$ ได้ $d(C_1)=2 = d(C_2)=2$ → **Tie-Break เลือก C_1!**
  จบรอบ 1 ได้: C_1=(7.5, 4.5), C_2=(3.33, 6.33)
- **ข้อ 2 (K=3, Euclidean, $C_1=A_2$, $C_2=A_5$, $C_3=A_8$):**
  จบรอบ 1: C_1=**(1.5, 3.5)**, C_2=**(7.0, 4.33)**, C_3=**(3.67, 9.0)**
  Converge ทันที!

15 · ประเมิน Cluster: Elbow · Silhouette · Profiling

Lect08 p30–38 · W7 Q9–11

- W7-Q9 **Inertia (WCSS):** $\Sigma \|x - C_k\|^2$ (ใช้ **Squared Euclidean**) · เพิ่ม K ค่า Inertia ย่อมลดเสมอ → **Elbow Method** เลือกค่า K ณ **จุดหักศอกที่อัตราการลดลงเริ่มชะลอตัวชัดเจน** (ไม่ใช่จุดที่ Inertia = 0)
- W7-Q10 **Silhouette Score:** $s(i) = [b(i) - a(i)] \div \max[a(i), b(i)]$ มีค่า $[-1, +1]$ · **เข้าใกล้ +1 = ดีเยี่ยม** (ในกลุ่มแน่น a ต่ำ, ห่างกลุ่มอื่น b สูง) · ใกล้ 0 = กำกึ่ง · ติดลบ = จัดผิดกลุ่ม
- W7-Q11 **Responsible Clustering:** ได้ Cluster 0/1/2 แล้ว **ต้องทำ Cluster Profiling เพื่อแปลงเป็น Business Persona** ก่อนนำไปใช้ (ห้ามใช้เลขกลุ่มตัดสิทธิ์ลูกค้าอัตโนมัติ)

16 · Black-Box vs White-Box & XAI อธิบายผล (SHAP)

Lect09 p04–09 · W8 Q1–5

- W8-Q1 **Black-Box Model:** โมเดลที่มีความซับซ้อนสูงมากจนมนุษย์ไม่สามารถทำความเข้าใจโครงสร้างภายใน หรืออธิบายเหตุผลทีละขั้นตอนได้อย่างชัดเจนว่าโมเดลคำนวณผลลัพธ์ออกมาได้อย่างไร แม้เราจะรู้ผลลัพธ์ (Output) จากข้อมูลที่ป้อนเข้าไป (Input) ก็ตาม · **ตัวอย่างชัดเจนที่สุด: Deep Neural Network ที่ซับซ้อนและมี Hidden Layer นับร้อย** เนื่องจากมีพารามิเตอร์และเส้นทางการคำนวณเชื่อมโยงมหาศาล (รวมถึง Random Forest, Complex Ensembles) · ต่างจาก **White-Box (Interpretable):** มนุษย์เข้าใจตรรกะได้ตรงไปตรงมา เช่น **Decision Tree ตื้น**, Linear / Logistic Regression
- W8-Q2,3 **ทำไม Acc 84% ยังไม่อนุมัติ:** บดบังผลต่ำในกลุ่มย่อย (**Recall ลูกค้าใหม่แค่ 54%**) ยังไม่ได้ตรวจผลกระทบ/จริยธรรม · ภาพรวมพึ่งพาปัจจัยใด = **Global Explanation** · ทำไมลูกค้ารายนี้ได้ 65% = **Local Explanation**
- W8-Q4 **Model-Specific vs Agnostic:** Specific อิงโครงสร้างเฉพาะ · **Agnostic** มองโมเดลเป็น Black-Box ตรวจผ่าน Input–Output ใช้ได้กับทุกโมเดล (**SHAP, LIME**)

W8-Q5 **วิธีอ่านค่า SHAP (สไลด์ p09):** Base = **32%**, ทายรายนี้ = **65%** · สมการ: 32% + 29% (**ไม่ซื้อนาน**) + 12% − 8% = 65%

- **คำแปลผล SHAP = +29%:** ปัจจัย "ไม่ซื้อนาน" ดันความน่าจะเป็น Inactive **เพิ่มขึ้น 29 จุดเปอร์เซ็นต์ (Percentage Points) เทียบค่าฐาน** (ไม่ใช่เพิ่ม 29% หรือ 29 วัน)

17 · Concept Drift · Bias · Proxy · คดีจริยธรรม AI

Lect09 p10–28 · W8 Q6–11

- W8-Q6,7 **Concept Drift:** โลกเปลี่ยนทำให้ **ความสัมพันธ์ P(Y|X) เปลี่ยน** (เปิด Sub ส่งของอัตโนมัติ กฎเดิมพัง Recall ตกเหลือ 54%) ต่างจาก **Data Drift** ที่เปลี่ยนแค่ P(X) · **Proxy:** ลบเพศ/สีผิวไม่พอ เพราะตัวแปรอื่น (เช่น **รหัสไปรษณีย์ Postal Code**) ทำหน้าที่แทนโดยอ้อม
- W8-Q9 **Data Privacy & Governance: Purpose Limitation** (ใช้ตามวัตถุประสงค์ที่แจ้ง) + **Data Minimization** (เก็บเท่าที่จำเป็น) · **Consent ไม่ใช่ฐานเดียว** และห้ามส่งข้อมูลเข้า GenAI ภายนอกแค่ตัดชื่อออก!

กรณีศึกษาในสไลด์	สาเหตุความผิดพลาดเชิงจริยธรรม & บทลงโทษที่ออกสอบ
Health-risk W8-Q8 (Obermeyer 2019)	ใช้ **ค่ารักษาในอดีตเป็น Proxy ความต้องการรักษา → ผู้ป่วยผิวดำที่ป่วยหนักเท่ากันได้คะแนนความเสี่ยงต่ำกว่าจริง** เพราะเข้าถึงการรักษาน้อยกว่า (แก้แล้วได้สิทธิ์เพิ่ม 17.7% → 46.5%)
Rite Aid W8-Q10 (FTC 2023–24)	ระบบจดจำใบหน้าเกิด False Positive แล้ว **พนักงานจับกุมทันทีโดยไม่มี Human Checkpoint ตรวจซ้ำ** → FTC สั่งแบนระบบใบหน้า 5 ปี
iTutor / Meta	**iTutorGroup:** กรองอายุอัตโนมัติ (หญิง>55, ชาย>60) ปรับ $365k · **Meta:** โฆษณาบ้านคัดเพศ/สีผิว ปรับ $115k

W8-Q11 **การสื่อสารกับ Stakeholders:** ปรับภาษาตามผู้ฟังได้ **แต่ห้ามเปลี่ยนข้อเท็จจริง** ต้องแจ้งข้อจำกัด ความไม่แน่นอน และมี **Human Oversight** กำกับเสมอ

18 · CRISP-DS in Action: ทีมข้อมูล · สัญญา · Handoff

Lect10 · W9 Q2–11

บทบาทสาย Business / Infra W9-Q2,3,4	บทบาทสาย Data Science / MLE W9-Q5,6,10
BA: ทำ **Decision Contract** ร่วมกับ BU ล็อกเป้าหมาย W9-Q3	**DA:** ทำ EDA ส่งมอบ **ข้อค้นพบทางสถิติ/ข้อจำกัดข้อมูล** (ไม่ใช่โค้ด/แดชบอร์ด) W9-Q5
DE: **สร้าง Data Pipeline ดูแล Platform & โครงสร้างพื้นฐาน** W9-Q2	**DS:** สร้างโมเดล: **Decision Tree ทำนายเสี่ยง · K-Means ดูพฤติกรรม** W9-Q6
AE: สร้าง Customer Table & **Feature Contract** (กัน Leakage) W9-Q4	**MLE: เตรียมผลตาม Pilot Runbook** ส่วนฝ่ายธุรกิจเป็นผู้อนุมัติใช้ W9-Q10

เจาะลึก 5 ประเด็นสำคัญที่ออกสอบสั้น Week 9: • W9-Q3,9 **Decision Contract** ทำตอนเริ่ม (ล็อกขอบเขต) · **Decision Memo** ทำตอนประเมิน (บันทึกผล/เงื่อนไขทดสอบ ไม่ใช่รับรองถาวร!) • W9-Q4 **Feature Contract:** เกิดก่อนเวลาตัดสินใจ ($T < T_0$) เท่านั้น • W9-Q7,8,11 **Predictive→Prescriptive:** แนะสิ่งที่ควรทำ (Action+Constraints) · **AI Assistant:** Draft ให้คนอนุมัติ · **Recall ตก:** สั่งพักใช้ (Pause Pilot)

19 · สรุปทางลัดตัดช้อยส์ไว (Quick Exam Elimination Rules จากข้อสอบในห้องเรียน 60 ข้อ)

ทบทวนก่อนเข้าห้องสอบ

หมวด EDA & Data Prep (W4)	หมวด Modeling & Tree (W5–W6)	หมวด Metrics & K-Means (W6–W7)	หมวด Responsible AI & Action (W8–W9)
• เบ้ขวาหนัก/มี Outlier → **Median + IQR** • 2 ยอด (Bimodal) → **มีกลุ่มย่อยแฝงอยู่** • นอกรั้ว Q3+1.5·IQR → **สืบค้นก่อน ห้ามลบทิ้ง** • มีจุดกลางเทียบเป้าหมาย → **Diverging Palette**	• ถามสถิติเดือนที่แล้ว → **Descriptive (ไม่ใช้ ML)** • Trained Model → **Fitted Tree ที่เทรนแล้ว** • จูน max_depth → **ดูผลบน Validation เท่านั้น** • ข้อย์บอก "จูนบน Test Set" → **ถ้าผิดทันที!**	• งบ/ทีมจำกัด (กลัวทายบวกผิด) → **Precision** • ห้ามหลุดกลุ่มเสี่ยง/โรคร้าย → **Recall** • K-Means: **Max Intra + Min Inter**, เร็ว O(tkn) • Centroid ใหม่ = **ค่าเฉลี่ย (Mean) ของสมาชิก**	• Black-Box ตัวอย่างชัดสุด → **Deep Neural Net (Hidden Layers นับร้อย)** • ลบเพศ/สีผิวแล้วยังอคติ → **Proxy (รหัสไปรษณีย์)** · Drift → **P(Y|X) เปลี่ยน** • Rite Aid → **ขาด Human Checkpoint** · เริ่ม = **Contract** · ประเมิน = **Memo**